

Mathématiques 2 : Algorithme PageRank de Google


HE Vinci : Informatique orientation développement d'applications

31 mars 2025

PageRank de Google

But : classer les sites par pertinence lors d'une recherche Google

1) Recherche sur mots clef : obtention d'un réseau de pages internet :




Comment les classer par pertinence ?

- ⇒ En fonction du nombre de consultations de chaque page ;
- ⇒ Processus de Markov : temps moyen passé sur chaque état !
- ⇒ Distribution stable !

PageRank de Google

2) Matrice d'adjacence :

- Matrice carrée d'ordre n où n est le nombre de pages ;
- $m_{ij} = \begin{cases} 1 & \text{si il y a un hyperlien de la page } j \text{ vers la page } i \\ 0 & \text{sinon} \end{cases}$



$$\begin{pmatrix} 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix}$$

La matrice obtenue n'est pas colonne-stochastique

PageRank de Google

- 3) On suppose que l'internaute choisi de manière équiprobable l'hyperlien sur lequel il clique

Exemple : s'il y a 2 hyperliens sur une page, chaque hyperlien a 1 chance sur 2 d'être choisi.

Pour notre réseau on a

$$\begin{pmatrix} 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix} \Rightarrow \begin{pmatrix} 0 & 1 & \frac{1}{4} & \frac{1}{3} & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{3} & \frac{1}{2} & 1 & 0 \\ 0 & 0 & \frac{1}{4} & 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & 0 \end{pmatrix}$$

⚠ La nouvelle matrice obtenue n'est toujours pas colonne-stochastique !

⇒ la dernière colonne n'a que des 0

⇒ la page 7 n'a pas d'hyperlien ⇒ **trou noir**

PageRank de Google

4) Gestion des trous noirs :

S'il n'y pas d'hyperlien, l'utilisateur peut taper n'importe quel adresse de page internet dans la barre d'adresse !

⇒ Depuis cette page on peut aller vers n'importe quelle page !


Pour notre réseau cela donne :

$$\begin{pmatrix} 0 & 1 & \frac{1}{4} & \frac{1}{3} & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{3} & \frac{1}{2} & 1 & 0 \\ 0 & 0 & \frac{1}{4} & 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & 0 \end{pmatrix} \Rightarrow M = \begin{pmatrix} 0 & 1 & \frac{1}{4} & \frac{1}{3} & 0 & 0 & \frac{1}{7} \\ 1 & 0 & 0 & 0 & 0 & 0 & \frac{1}{7} \\ 0 & 0 & 0 & \frac{1}{3} & 0 & 0 & \frac{1}{7} \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & \frac{1}{7} \\ 0 & 0 & 0 & \frac{1}{3} & \frac{1}{2} & 1 & \frac{1}{7} \\ 0 & 0 & \frac{1}{4} & 0 & \frac{1}{2} & 0 & \frac{1}{7} \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & \frac{1}{7} \end{pmatrix}$$

La matrice M obtenue est colonne-stochastique !

PageRank de Google

4) Regardons le processus de Markov ainsi obtenu :



Classes de communication et type d'états :

- $C_1 = \{1, 2\}$: récurrents ;
- $C_2 = \{3, 4, 7\}$: transients ;
- $C_3 = \{5, 6\}$: récurrents.

- ⇒ proportion du temps passé sur les états de la classe $C_2 = 0$;
- ⇒ 2 classes d'états récurrents : plusieurs distributions stables possibles ;
- ⇒ théorème de convergence pas applicable

PageRank de Google

5) Introduction de l'aléatoire :

Probabilité d'utiliser la barre d'adresse : changement de page équiprobable.

On prend comme matrice de transition :

$$P = \alpha \cdot \begin{pmatrix} 0 & 1 & \frac{1}{4} & \frac{1}{3} & 0 & 0 & \frac{1}{7} \\ 1 & 0 & 0 & 0 & 0 & 0 & \frac{1}{7} \\ 0 & 0 & 0 & \frac{1}{3} & 0 & 0 & \frac{1}{7} \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & \frac{1}{7} \\ 0 & 0 & 0 & \frac{1}{3} & \frac{1}{2} & 1 & \frac{1}{7} \\ 0 & 0 & \frac{1}{4} & 0 & \frac{1}{2} & 0 & \frac{1}{7} \\ 0 & 0 & \frac{1}{4} & 0 & 0 & 0 & \frac{1}{7} \end{pmatrix} + (1 - \alpha) \cdot \begin{pmatrix} \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \\ \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \\ \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \\ \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \\ \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \\ \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \\ \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} & \frac{1}{7} \end{pmatrix}$$

où $\alpha = 0.85$.

La matrice P n'a pas de 0 $\Rightarrow$ une seule classe de communication apériodique.
 $\Rightarrow$ le théorème est applicable.

PageRank de Google

5) Recherche de la distribution :

- a) Choix d'une distribution de départ $d^{(0)}$.
- b) Calcul de $d^{(k+1)} = P \cdot d^{(k)}$ jusqu'à convergence.

 Il faut normaliser la distribution $d^{(k)}$ à chaque itération !

Normalisation : la somme des éléments de $d^{(k)}$ doit être égale à 1 :

- i) Calcul de la somme des éléments de $d^{(k)}$: $s = d_{11}^{(k)} + d_{21}^{(k)} + \dots + d_{n1}^{(k)}$.
- ii) - Normalisation : faire $d_{i1}^{(k)} = d_{i1}^{(k)} / s$ pour tous les éléments de $d^{(k)}$.

PageRank de Google : Algorithme

Supposons un réseau de n pages.

- 1) Matrice d'adjacence $A : a_{ij} = \begin{cases} 1 & \text{si hyperlien de l'état } j \text{ vers l'état } i \\ 0 & \text{sinon} \end{cases}$.
- 2) Normalisation de la matrice d'adjacence : hyperliens équiprobables
- 3) Gestion des trous noirs : ajout de liens vers toutes les pages.
 $\Rightarrow$ colonne de 0 remplacée par colonne de $\frac{1}{n}$
 $\Rightarrow$ obtention d'une matrice M colonne-stochastique
- 4) Gestion des classes récurrentes multiples : introduction de l'aléatoire :


$$P = \alpha \cdot M + (1 - \alpha) \cdot \begin{pmatrix} \frac{1}{n} & \cdots & \frac{1}{n} \\ \vdots & \ddots & \vdots \\ \frac{1}{n} & \cdots & \frac{1}{n} \end{pmatrix} \quad \text{avec } \alpha = 0.85$$

- 5) Choix d'une distribution de départ
- 6) 85 itérations avec normalisation de la distribution à chaque itération

PageRank de Google

Exercice

Trouvez le PageRank des pages du réseau ci-dessous.




PageRank de Google

Exercice

Résolution :

1) Numérotation des pages et matrice d'adjacence :



$$\begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \end{pmatrix}$$

PageRank de Google

Exercice

2) Equiprobabilité :

$$\begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \end{pmatrix}$$

 $\Rightarrow$

$$\begin{pmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & \frac{1}{2} & 0 \\ 0 & \frac{1}{3} & 0 & \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{3} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ 0 & \frac{1}{3} & \frac{1}{3} & \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}$$

3) Gestion des trous noirs $\Rightarrow$ Page 6.

$$\begin{pmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & \frac{1}{2} & 0 \\ 0 & \frac{1}{3} & 0 & \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{3} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ 0 & \frac{1}{3} & \frac{1}{3} & \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}$$

 $\Rightarrow$

$$\begin{pmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & \frac{1}{6} \\ 1 & 0 & 0 & 0 & \frac{1}{2} & \frac{1}{6} \\ 0 & \frac{1}{3} & 0 & \frac{1}{2} & 0 & \frac{1}{6} \\ 0 & \frac{1}{3} & 0 & 0 & 0 & \frac{1}{6} \\ 0 & 0 & \frac{1}{3} & 0 & 0 & \frac{1}{6} \\ 0 & \frac{1}{3} & \frac{1}{3} & \frac{1}{2} & \frac{1}{2} & \frac{1}{6} \end{pmatrix}$$

PageRank de Google

Exercice

4) Introduction de l'aléatoire :


$$P = 0.85 \cdot \begin{pmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & \frac{1}{6} \\ 1 & 0 & 0 & 0 & \frac{1}{2} & \frac{1}{6} \\ 0 & \frac{1}{3} & 0 & \frac{1}{2} & 0 & \frac{1}{6} \\ 0 & \frac{1}{3} & 0 & 0 & 0 & \frac{1}{6} \\ 0 & 0 & \frac{1}{3} & 0 & 0 & \frac{1}{6} \\ 0 & \frac{1}{3} & \frac{1}{3} & \frac{1}{2} & \frac{1}{2} & \frac{1}{6} \end{pmatrix} + 0.15 \cdot \begin{pmatrix} \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \end{pmatrix}$$

PageRank de Google

Exercice

5) Choix d'une distribution de départ suivi 85 itérations :

$$d^{(0)} = \begin{pmatrix} \frac{1}{6} \\ \frac{1}{6} \\ \frac{1}{6} \\ \frac{1}{6} \\ \frac{1}{6} \\ \frac{1}{6} \\ \frac{1}{6} \end{pmatrix} \xrightarrow{85 \text{ itérations}} d^{(85)} = \begin{pmatrix} 0.112731386620343 \\ 0.207157903921133 \\ 0.174021178729935 \\ 0.122120125424516 \\ 0.112731386620343 \\ 0.271238018683729 \end{pmatrix}$$



⇒ Classement des pages : 6,2,3,4,5,1.

PageRank de Google : Implémentation

1) Exercice 12.2 sur Papier

2) Implémentation :

Dans la classe Matrice, implémenter la méthode

```
public Matrice pageRank()
```

qui renvoie la matrice mesurant l'ordre d'importance de chaque page du réseau.
si la matrice courante représente la matrice d'adjacence d'un réseau d'hyperliens
(m_{ij} 1 si la page j pointe vers la page i et 0 sinon),

Sinon lance une `MathException`

PageRank de Google : Implémentation

Pour y arriver, on veillera à suivre les étapes suivantes :

- a) Vérifier que la matrice ne contient que des 1 et des 0, lancer une `MathException` dans le cas contraire.
- b) Créer la matrice de transition correspondant à la matrice du réseau sans oublier de prendre en compte le problème des trous noirs.
- c) Créer la matrice Google du réseau pour contourner le problème des multiples classes récurrentes.
- d) Associer une matrice d'état initial v_0 cohérente pour pouvoir par la suite calculer la distribution limite.
- e) Trouver la distribution limite à l'aide du théorème de convergence en veillant à chaque étape à normaliser vos matrices pour éviter les erreurs machines.

Conseils :

- Séparer votre méthode en sous-méthodes (étapes a) à c) par exemple)
- Testez votre méthode `pageRank()` grâce à la classe `TestPageRank`.